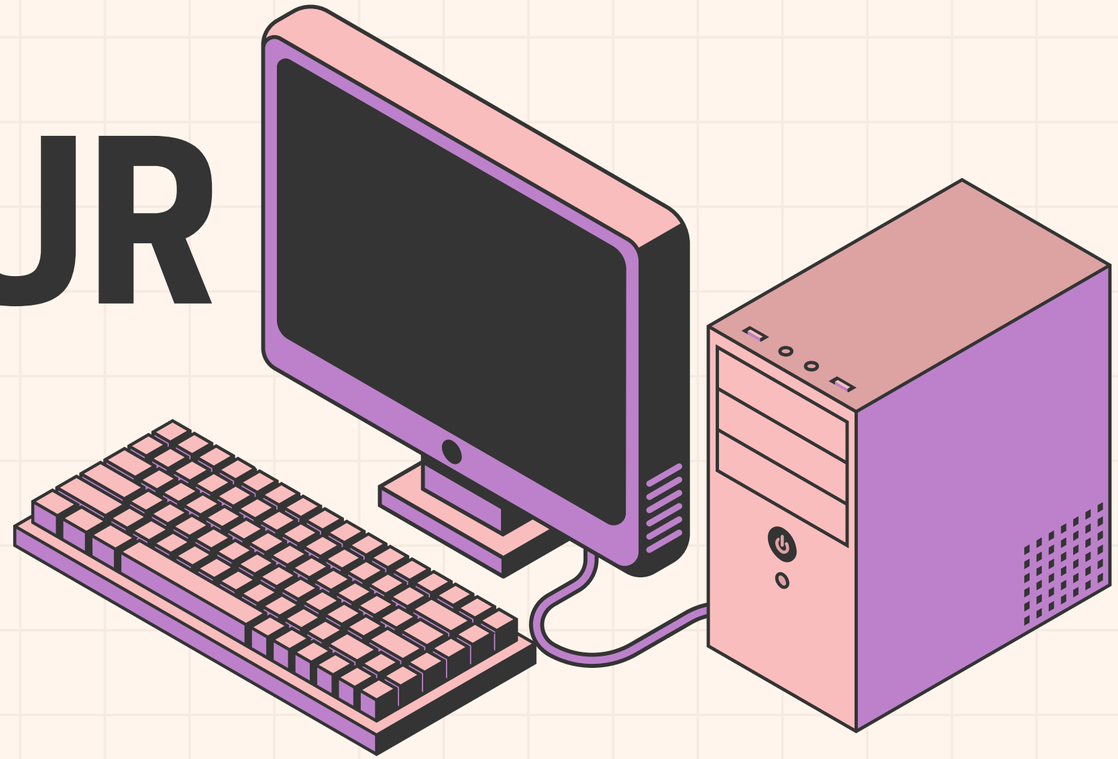
YÜZEY KUSUR TESPİTİ



Yusuf Gülmez - Y255012073
Rıfat Öztürk - Y255012072

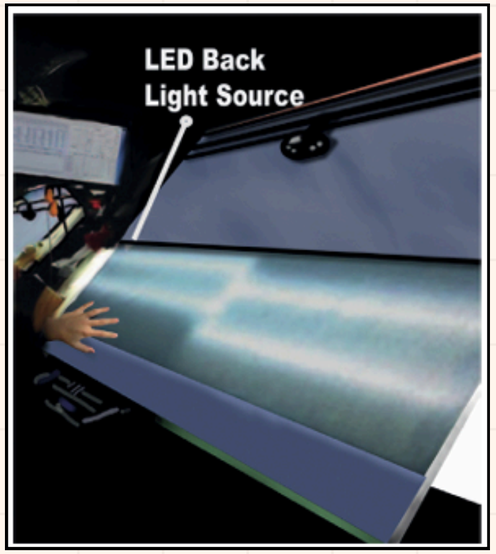
YÜZEY KUSUR TESPİTİ NEDİR VE NEDEN ÖNEMLİDİR?

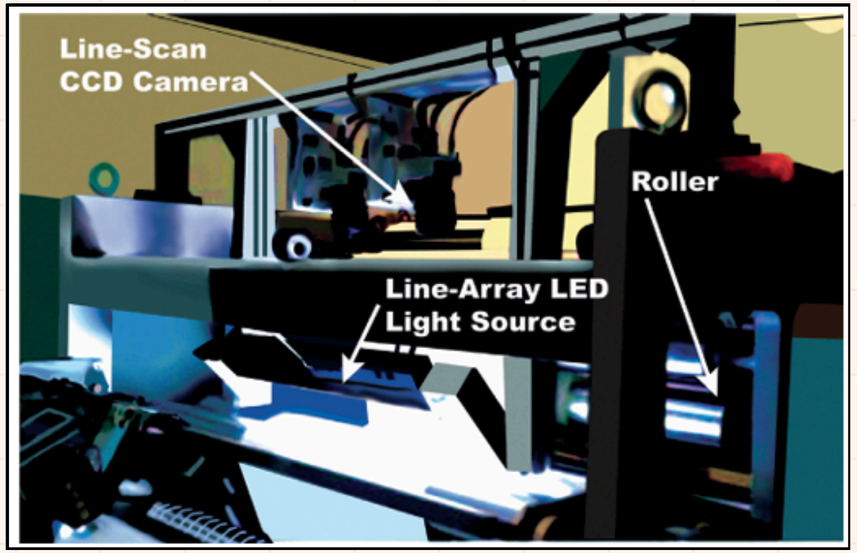
Bir fabrikada üretilen çelik, kumaş veya elektronik bir **parçanın kalitesi ve fiyatı doğrudan yüzeyinin kusursuz olmasına bağlıdır**. Literatürdeki çalışmalara göre, örneğin tekstil endüstrisinde bir üründe kusur bulunması, o ürünün **piyasa değerini %45 ile %65 arasında düşürebilmektedir.**

Geçmişten günümüze fabrikalar bu kusurları bulmak için 'kalite kontrol uzmanları' yani insanları çalıştırıyor. Ancak makalelerden elde ettiğimiz verilere göre **manuel kontrolün çok ciddi sınırları var:**

- Bir insanın üretim bandında maksimum **odaklanma süresi ortalama 10 dakikadır.**
- Personel, devasa hataları görse bile, **minör (çok küçük) çizik veya lekeleri gözden kaçırmaktadır.**

Çözüm: **Bilgisayarlı Görme (Computer Vision)** ile yüksek hızlı, kesintisiz ve hatasız otomatik denetim.





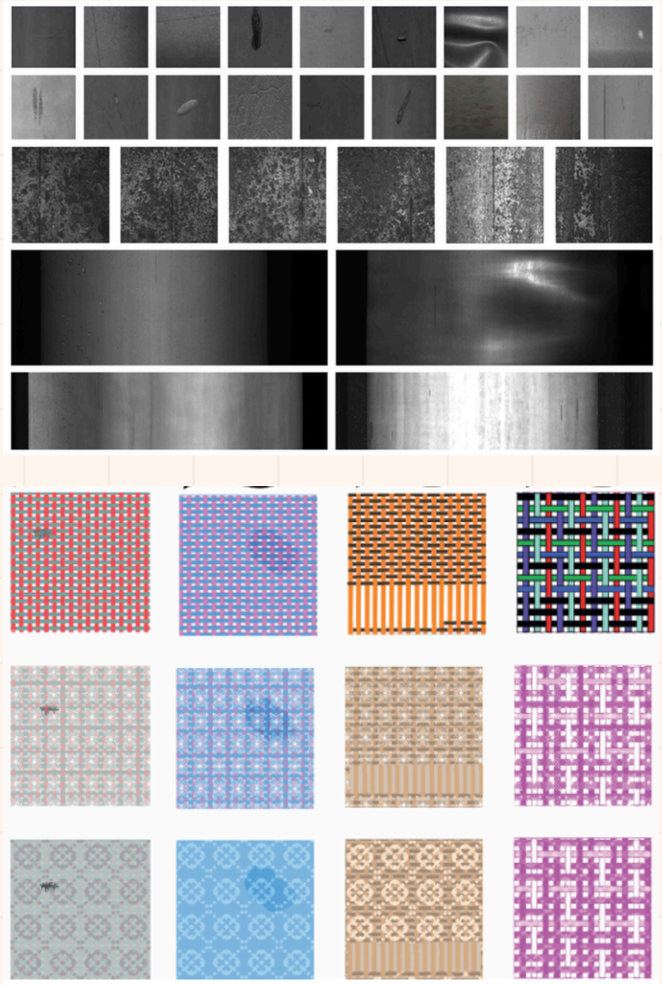
ENDÜSTRİYEL SEKTÖRLERDEN KUSUR ÖRNEKLERİ

Yüzey kusuru dediğimizde **aklımıza sadece tek bir materyal veya tek bir sektör gelmemeli.** Ekranda gördüğünüz makalelerden alınmış görseller, bu problemin endüstrinin ne kadar geniş bir alanına yayıldığını kanıtlıyor.

- **Tekstil ve Kumaş Endüstrisi:** Kumaş üzerindeki delikler (hole), yağ lekeleri (oil stain), kalın/ince çubuk hataları ve kopuk iplikler (broken weft).
- **Metal ve Ağır Sanayi:** Çelik şeritlerde ve levhalarda meydana gelen üretim kusurları.

Yaptığımız araştırmalar sonucunda **ağır sanayide üretilen çelik şeritlerin** denetiminden, altyapıdaki **demiryolu raylarının yüzey kontrolüne** kadar çok geniş bir yelpaze var. **Akıllı telefonların ekranlarındaki çok ufak çiziklerin tespiti** bu alanın konusudur.

Her sektöre uyacak **evrensel 'tek bir sihirli algoritma' geliştirmek oldukça zordur.** Bu yüzden her sektöre özel farklı yöntemler uygulanıyor.



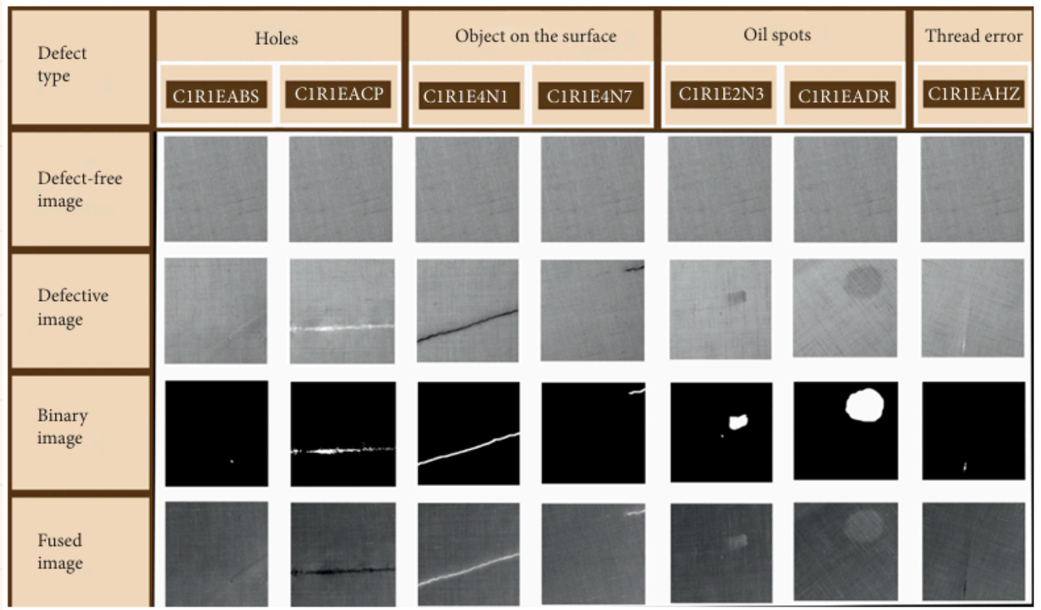
GELENEKSEL BİLGİSAYARLI GÖRME YÖNTEMLERİ NASIL ÇALIŞIR?

Geleneksel yöntemlerin temel mantığı şudur: Bilgisayarın kendi kendine öğrenmesi yerine, mühendislerin sisteme **katı matematiksel kurallar yazması gerekir.** Literatürde bunlara **'özellik çıkarımı' (feature extraction)** denir.

Örneğin bir kameradan **görüntü alınır**, **filtrelerle gürültüsü temizlenir.** Ardından **'Kenar Bulma' (Edge Detection)** algoritmalarıyla—örneğin **Sobel** veya **Canny** filtreleri ile—yüzeydeki keskin **renk geçişleri**, yani **çatlaklar** veya **delikler tespit** edilmeye çalışılır.

Başka bir popüler yöntem ise **Frekans analizidir**. Hızlı Fourier Dönüşümü (FFT) gibi araçlarla, düzenli bir kumaş veya düz bir **çelik levhadaki standart doku ritmi bilgisayara tanıtılır.** Bu **ritmi bozan** herhangi bir 'anomali' eşikleme **(thresholding)** yöntemiyle kesilip siyah-beyaz olarak ekrana yansıtılır.

Harika gibi duran bu matematiksel filtrelerin çok ciddi sınırları vardır.



GELENEKSEL YÖNTEMLERİN SINIRLARI VE ZORLUKLARI

Geleneksel yöntemler **düz, mat ve sabit ışık altındaki yüzeylerde harika çalışır.** Ama gerçek bir fabrikanın üretim bandı asla böyle steril değildir.

Birinci büyük sorun **ışıktır**. Klasik histogram veya eşikleme (threshold) metotları aydınlatmadaki en ufak bir değişimi veya kameradaki elektriksel bir gürültüyü 'kusur' olarak algılayıp sistemi durdurabilir.

İkinci sorun **doku karmaşıklığıdır**. Ekranda gördüğünüz gibi birden fazla iplik renginin karıştığı, kendinden desenli bir kumaşta veya sürekli parlayan bir çelik levhada neyin 'arka plan' neyin 'çatlak' olduğunu **matematiksel bir filtreyle ayırmak neredeyse imkansızdır.**

Çok desenli kumaşlar, ipliği boyalı (**yarn-dyed**) tekstiller veya yansımalı metal yüzeylerdeki hataları tanımlamak çok zordur.

Burada ise devreye kendi kendine öğrenebilen bir teknoloji olan **Derin Öğrenme** kavramı giriyor.



MAKİNE ÖĞRENMESİNE GEÇİŞ

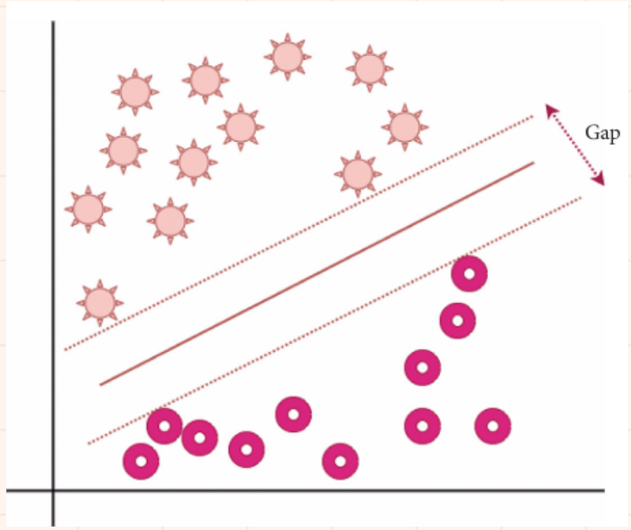
Önceki slaytta klasik filtrelerin karmaşık dokularda veya ışık değişimlerinde çöktüğünden bahsetmiştik. Endüstri bu sorunu aşmak için '**Makine Öğrenmesi' (Machine Learning)** algoritmalarına yöneldi.

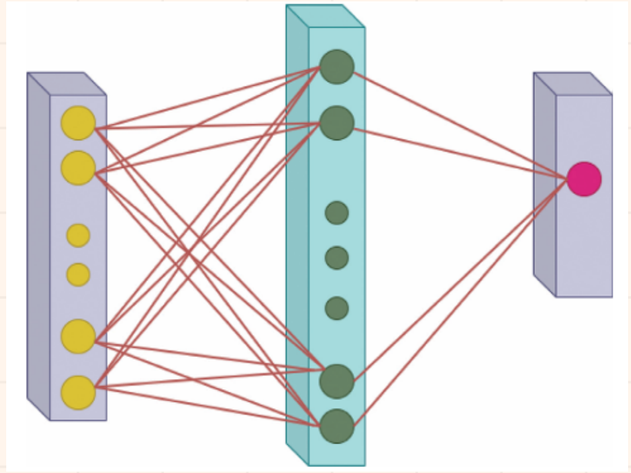
Algoritmaya verilen kusurlu ve kusursuz binlerce örnek sayesinde sistem aradaki kusuru kendisi bulabiliyor. Ekranda gördüğünüz **Destek Vektör Makineleri (SVM)** veya klasik **Yapay Sinir Ağları (ANN)** tam olarak bunu yapar. **Kusurluları bir tarafa, kusursuzları diğer tarafa ayırır.**

Bu klasik algoritmalar, kameradan gelen pikselleri (resmi) doğrudan **kendi başlarına anlayıp yorumlayamazlar. Gabor filtreleri, GLCM** veya **LBP** gibi matematiksel işlemlerle resimdeki özellikleri (features) elle hesaplaması ve algoritmaya hazır olarak sunulması gerekir.

Özellikleri **yanlış**, **eksik** veya **ortama uygunsuz** tasarlanırsa; **SVM** veya **ANN** ne kadar güçlü olursa olsun **sistem çöker.**

Bizi piksellerle **tek tek uğraşmaktan ve özellikleri manuel seçmekten kurtaran teknoloji** ise, '**Derin Öğrenme**' devrimidir.



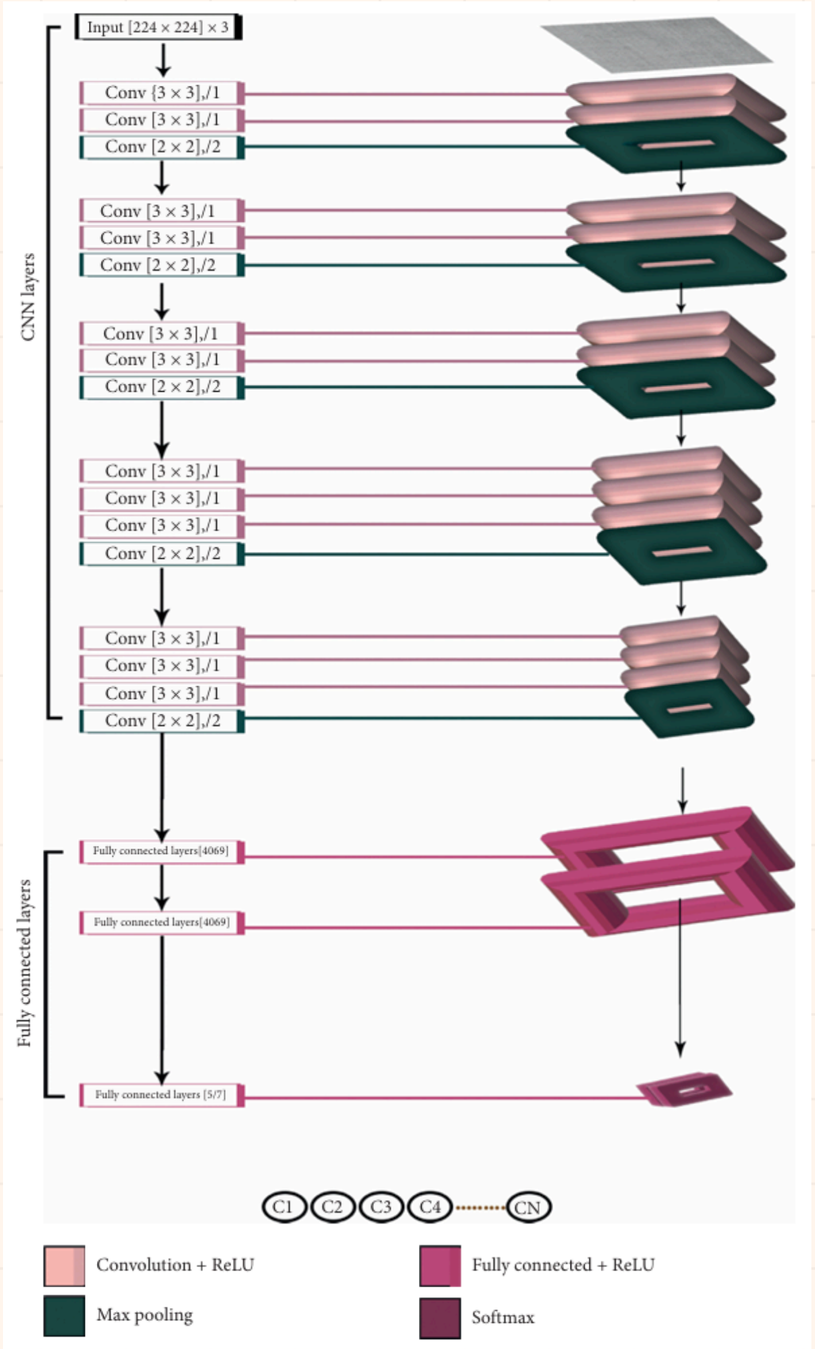


DERİN ÖĞRENME (DEEP LEARNİNG) DEVRİMİ

Eski sistemlerdeki en büyük eziyet özellikleri **manuel olarak çıkarmaktı. Derin Öğrenme**, özellikle de **Evrişimli Sinir Ağları (CNN'ler)** bizi bu yükten tamamen kurtardı.

Görselde bir **CNN modelinin (VGG-16)** mimarisi görünmektedir. Bu ağlara **'Uçtan Uca' (End-to-End)** öğrenen sistemler denir. **Modele ham kamera görüntüsünü verilir** ve sadece '**Bu resimde çizik var, bunda yok**' gibi bilgiler verilir. Geri kalan her şeyi; **o çiziğin neye benzediğini**, ışık parlamasıyla **gerçek bir çatlağın farkını**, dokunun örüntüsünü ağın kendisi gizli katmanlarında **matematiksel olarak keşfetmiş oluyor**. Bu sayede insan eli değmeden, sadece veriden öğrenmiş oluyor.

Bu sayede, **geleneksel yöntemlerin başarısız olduğu** ipliği boyalı kumaşlarda veya ışığın sürekli değiştiği çelik fabrikalarında bile **insanüstü bir doğruluk elde etmeye başlandı.** Peki bu modeller **endüstriyel üretim bantlarında ne kadar hızlı ve ne kadar başarılı çalışıyor?**

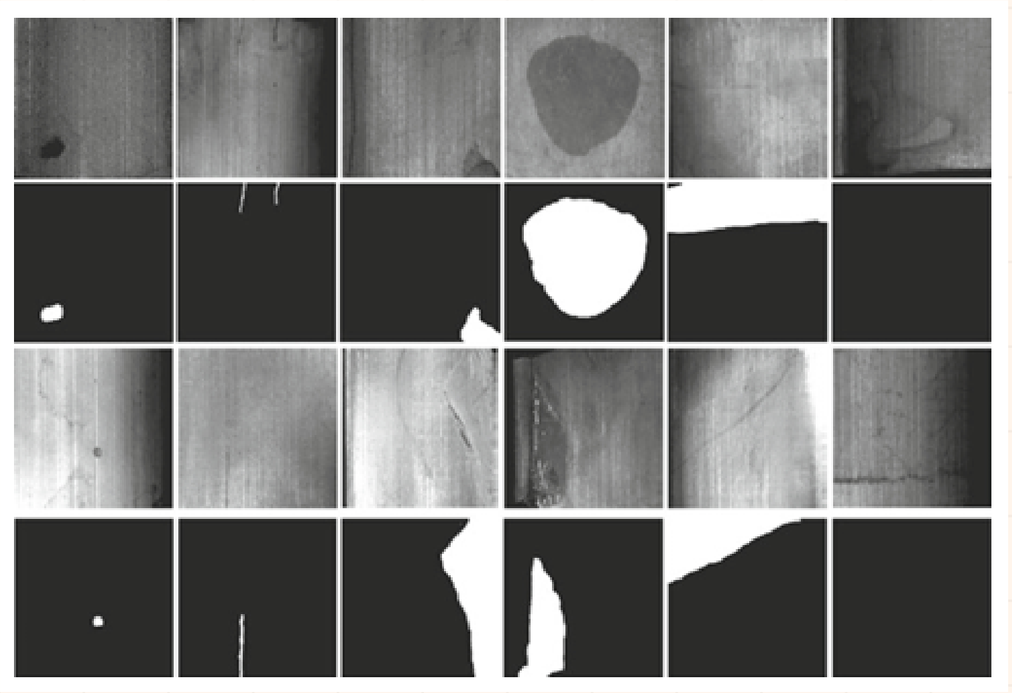


YÜKSEK HIZ VE HASSASİYET (NESNE TESPİTİ AĞLARI)

Fabrikalarda sadece **'Bu üründe kusur var'** demek yeterli değildir. Kusurun nerede olduğunu net bir şekilde işaretlemeniz gerekir ki hatalı kısım kesilip atılabilsin. İşte burada **'Nesne Tespiti' (Object Detection)** ağları devreye giriyor.

Literatürde bu iş için iki ana yaklaşım vardır: **Birincisi Faster R-CNN** gibi **'İki Aşamalı'** ağlar. Bu ağlar önce **resimde kusur olabilecek şüpheli bölgeleri bulur**, sonra **oraya odaklanıp karar verir**. Doğruluk oranları **%97**'lerin üzerindedir ancak yapıları gereği biraz **hantaldırlar.**

Ancak günümüz fabrikalarında **üretim bantları çok hızlı akar**. Saniyeler içinde onlarca ürünü denetlemeniz gerekir. İşte burada **YOLO (You Only Look Once)** gibi '**Tek Aşamalı**' ağlar devreye giriyor. YOLO, görüntüye sadece bir kez bakar ve hem **kusurun ne olduğunu** hem de **yerini tek seferde** söyler. İncelediğimiz çelik yüzeyi kusur tespiti makalelerinde, modifiye edilmiş **YOLO ağlarının saniyede tam 83 kareyi** (83 fps) işleyerek **%99 oranında kusur yakaladığını gördük**. Bu, insan gözünün asla yetişemeyeceği bir hız ve isabet oranıdır.



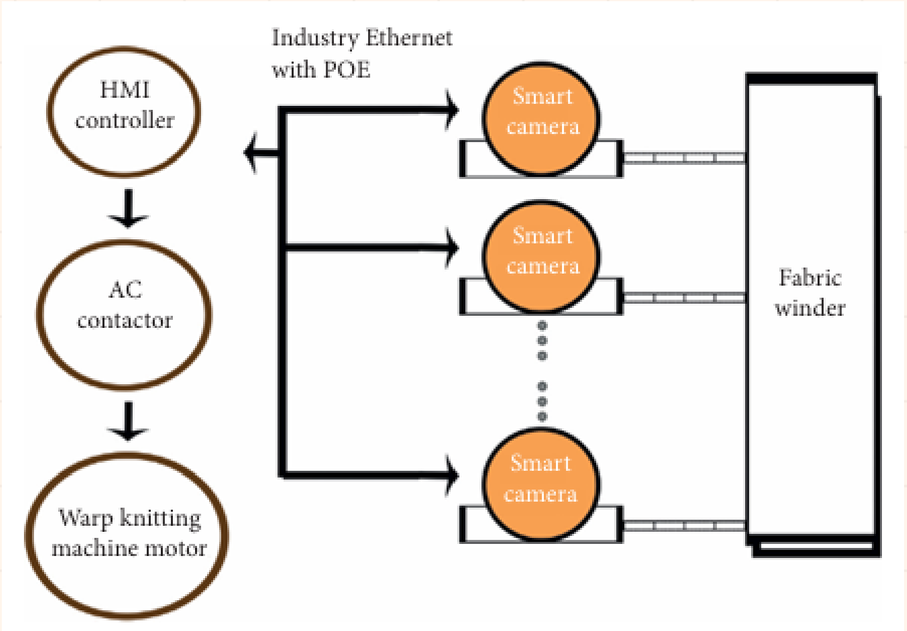
ÜRETİM HATTI İÇİN ÇÖZÜMLER

Derin öğrenme modelleri çok büyük **GPU**'lara (ekran kartlarına) ihtiyaç duyar, ancak fabrikalardaki bant kameraları genellikle **düşük işlem gücüne sahip gömülü sistemlerdir** (embedded devices).

Her üretim bandına on binlerce dolarlık devasa ekran kartları (GPU) takılamaz. Sistemin, kameranın içindeki **minik ve ucuz çiplere** entegre edilebilmesi gerekir. Makaleleri incelerken bilim insanları bu sorunu aşmak için '**Hafifletilmiş' (Lightweight) ağlar** geliştiriyor.

Örneğin bir çalışmada, **YOLO** algoritması özel yöntemlerle sıkıştırılıyor. Algoritmanın boyutu **241 megabayttan** sadece **8 megabayta düşürülüyor! Üstelik model küçülmesine rağmen hızı 2.6 kat artıyor** ve **başarı oranı düşmüyor.**

Aynı şekilde **Mobile-Unet** adını verdiğimiz mimariler, **kumaş dokularındaki hataları** üretim anında, **piksel piksel boyayarak gerçek zamanlı tespit edebiliyor.**

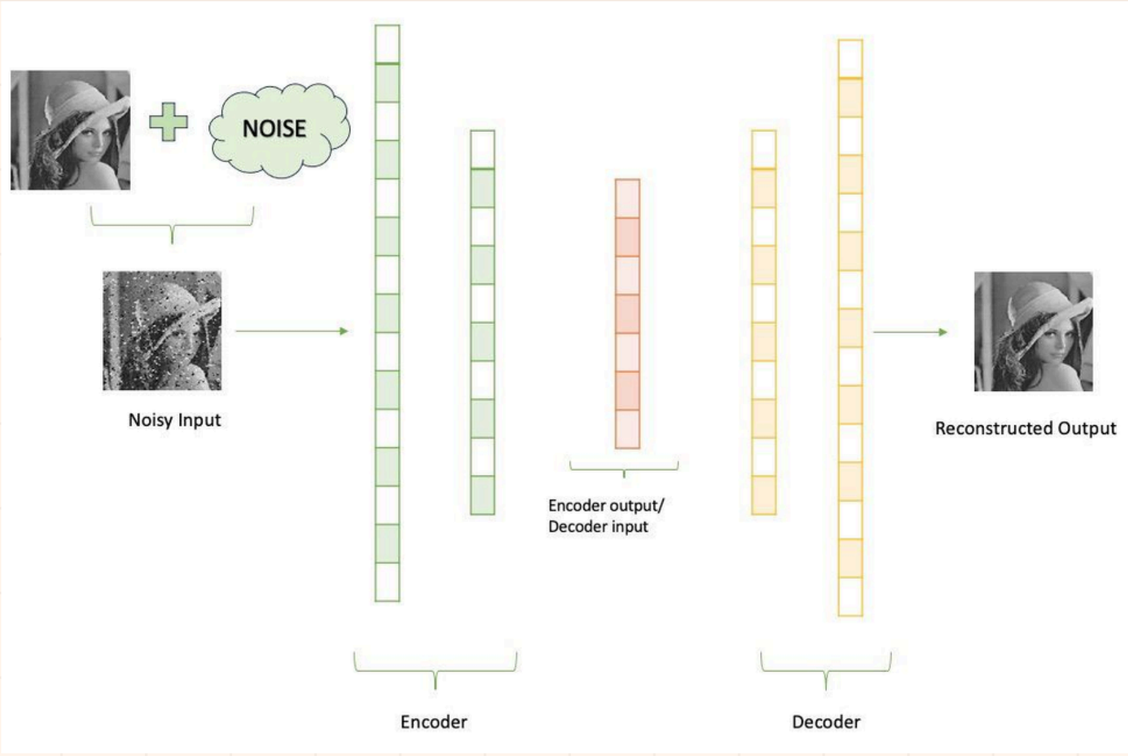


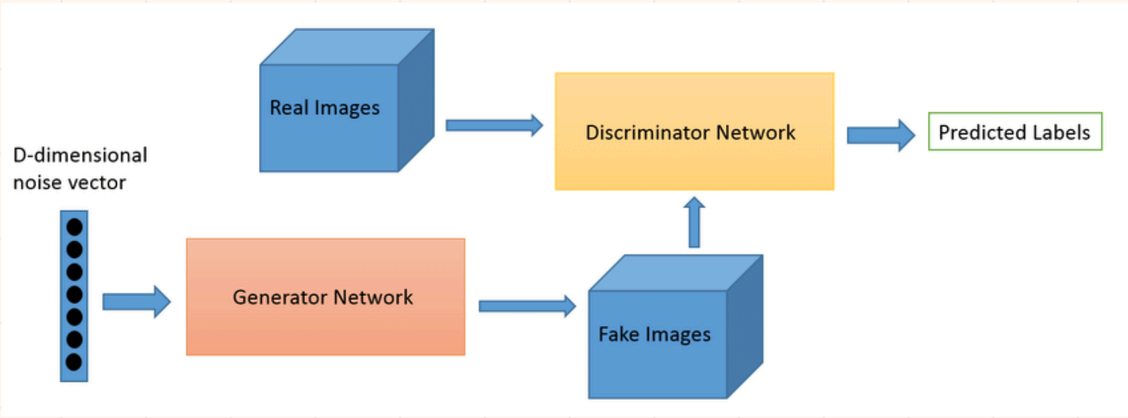
AZ VERİYLE BAŞA ÇIKMA

Fabrikalarda karşılaşılan ikinci devasa sorun ise şudur: **Veri kıtlığı**. Derin öğrenme milyonlarca "**kusurlu**" fotoğrafa ihtiyaç duyar, ancak kaliteli üretim yapan bir fabrikada kusurlu ürün bulmak çok nadirdir. İşte burada **Gözetimsiz Öğrenme** dediğimiz mükemmel bir mühendislik zekası devreye giriyor.

Otokodlayıcı (Autoencoder) veya **GAN** dediğimiz ağlar, kusursuz dokuyu ezberliyor. Üretim bandından çatlak bir çelik geldiğinde, sistem onu kendi ezberlediği 'kusursuz' haliyle baştan çizer. **Gelen hatalı ürün ile sistemin çizdiği mükemmel ürün birbirinden çıkarıldığında** (matematiksel subtraction), elde kalan tek şey o çatlak oluyor.

Ayrıca **DCGAN** gibi ağlar, elimizdeki **az sayıdaki kusuru kopyalayıp** sentetik (sahte) **kusurlu fotoğraflar üreterek veri setimizi büyütmemizi sağlıyor.** Sorgulanan görüntüyü normal dokuyla yeniden inşa edip "**olasılık haritaları**" çıkararak hatalı bölgeyi bulur.





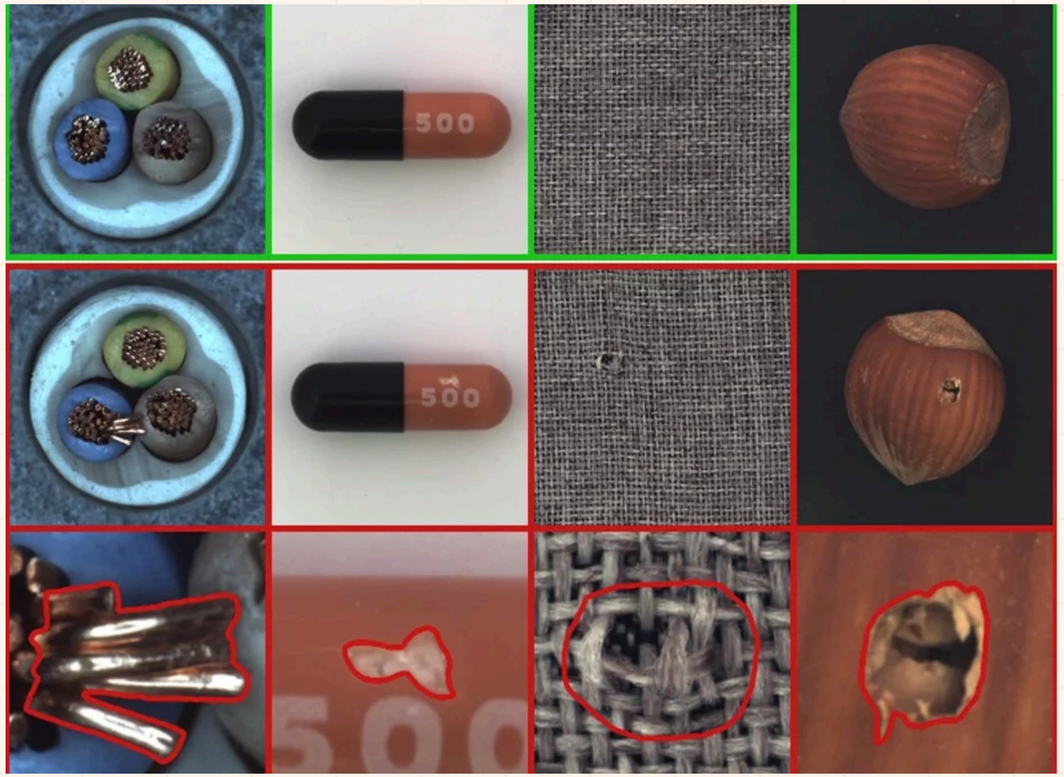
ENDÜSTRİYEL ZİRVE: MVTEC AD VERİ SETİ VE BAŞARIMLAR

MVTec AD endüstriyel anomali tespiti algoritmalarını test etmek için özel olarak tasarlanmış, 15 farklı nesne ve doku kategorisi içeren en zorlu ve prestijli veri setidir. İçerisinde halıdan deriye, vidadan bilgisayar kablolarına kadar çok çeşitli sanayi ürünleri barındırır.

PatchCore Ağı: Özellikle "Vida (Screw)" gibi zorlu donanım nesnelerinde 0.994 AUROC (neredeyse %100'e yakın kusursuzluk) skoruna ulaşmıştır.

SPADE ve PaDim: Deri, halı ve fırça gibi karmaşık dokularda 0.97 ile 1.00 arasında değişen çok yüksek tespit hassasiyetleri yakalamışlardır.

Donanım ve **veri** sağlandığında, yapay zeka fabrikalardaki insan hatasını **tamamen sıfırlama** noktasına gelmiştir.

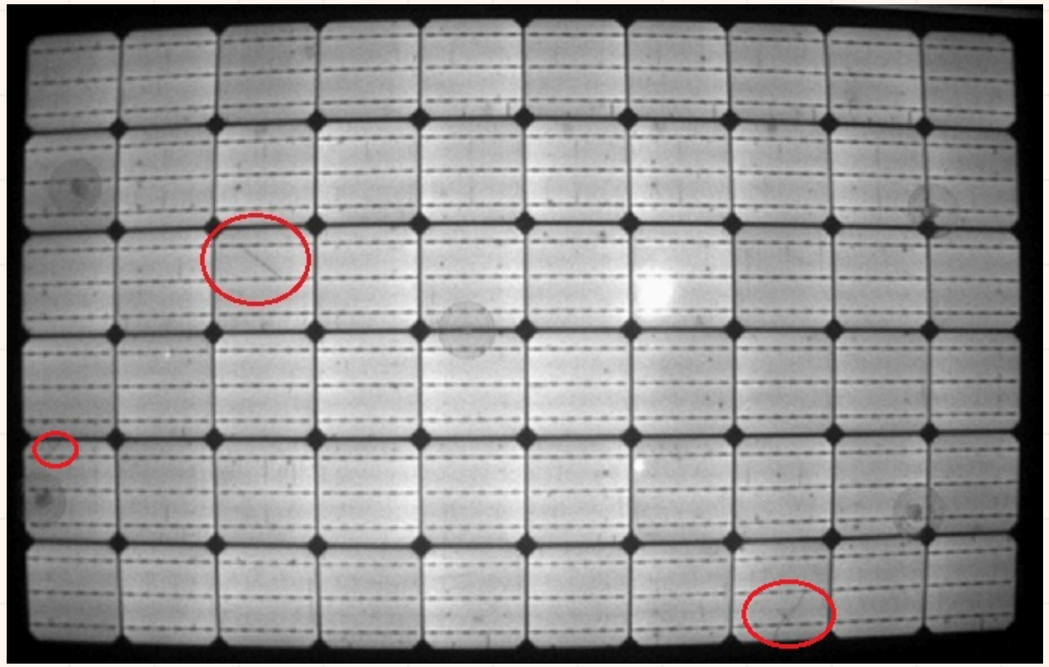


ÇÖZÜLMEYİ BEKLEYEN MÜHENDİSLİK ZORLUKLARI (DARBOĞAZLAR)

Güneş panellerindeki mikro çatlaklar veya devasa çelik levhalardaki kılcal çizikler, algoritmalar tarafından görüntü küçültüldüğünde kaybolmaktadır. Buna **Küçük Hedef Tespiti (Small Target Detection)** denir.

Mask R-CNN ve **Hız Sorunu:** Kusurun sadece yerini kutu içine almak yerine, **sınırlarını piksel piksel boyayan** (Segmentasyon) ağlar harika sonuç verir ancak gerçek zamanlı (real-time) çalışamayacak kadar yavaştır.

Sadece çelik yüzeyindeki çatlakları bulan bir yapay zeka ağı, kumaş fabrikasına götürüldüğünde hiçbir işe yaramamaktadır. **Buna aşırı özelleşme** sorunu denir.



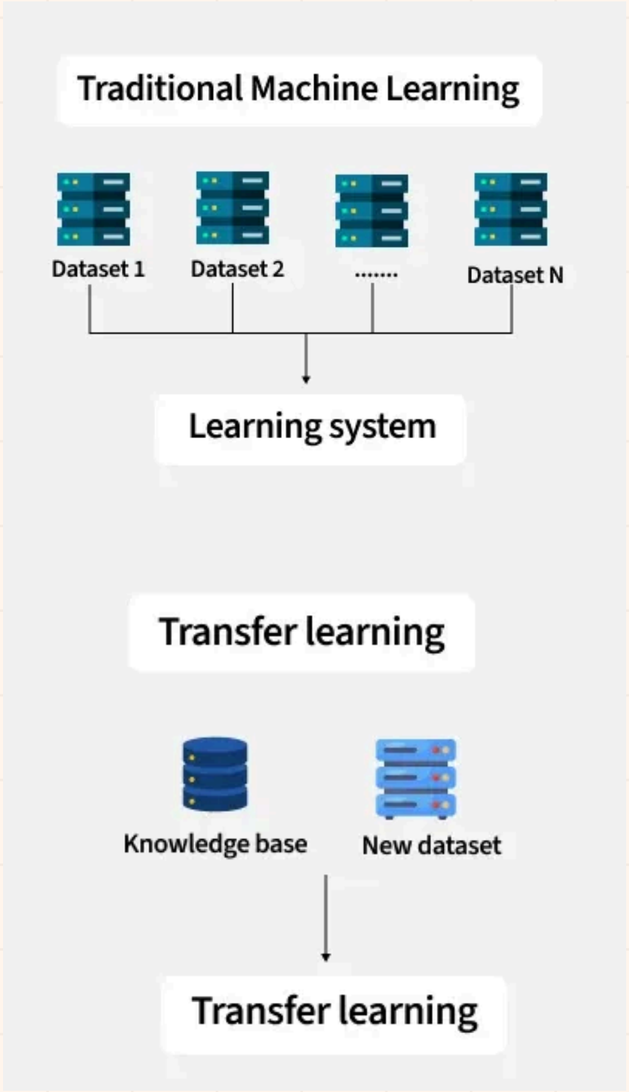
GELECEK TRENDLERİ VE ÇÖZÜM YOLLARI

Az Örnekle Öğrenme (Few-Shot Learning): Modelleri binlerce değil, sadece 5-10 adet kusurlu numune göstererek eğitebilme teknolojisi.

Transfer Öğrenimi (Transfer Learning): Başka bir sektörde (örneğin ahşap denetiminde) eğitilmiş bir yapay zekanın "görme yeteneğinin", hızlıca çelik fabrikasına kopyalanıp aktarılması.

Hibrit Sistemler: Klasik bilgisayarlı görmenin (Gabor filtreleri vb.) hızı ile derin öğrenmenin isabet oranını birleştiren melez yapılar.

Uç Bilişim (Edge Computing): Verilerin buluta gitmeden, doğrudan üretim bandındaki akıllı kameranın (sensörün) içinde anlık işlenmesi.



KARŞILAŞTIRMA

ÖZELLİK	Geleneksel Bilgisayarlı Görme	Derin Öğrenme (Deep Learning)
Kural Belirleme	Mühendis tarafından elle yazılır	Sistem veriden otomatik öğrenir
Donanım İhtiyacı	Çok düşük (Eski CPU'larda bile çalışır)	Yüksek (Özel GPU ve NPU'lar gerektirir)
Veri İhtiyacı	Düşük (Az veriyle kurallar yazılabilir)	Çok Yüksek (Büyük veri setleri ister)
Başarı ve Hassasiyet	Basit dokularda iyi, karmaşık dokularda kötü	Karmaşık, gürültülü ve desenli yüzeylerde mükemmel
Geliştirme Maaliyeti	Her yeni kusur tipi için kod baştan yazılır	Modelin yeni veriyle tekrar eğitilmesi yeterlidir

KAYNAKÇA

[1] B. Tang, L. Chen, W. Sun, ve Z. Lin, "Review of surface defect detection of steel products based on machine vision," IET Image Processing, cilt 17, ss. 303-322, 2023. DOI: 10.1049/ipr2.12647.

[2] Y. Chen ve diğerleri, "Surface Defect Detection Methods for Industrial Products: A Review," Applied Sciences, cilt 11, sayı 16, makale no. 7657, Ağu. 2021. DOI: 10.3390/app11167657.

[3] S. Qi, J. Yang, ve Z. Zhong, "A Review on Industrial Surface Defect Detection Based on Deep Learning Technology," Proceedings of the 2020 3rd International Conference on Machine Learning and Machine Intelligence (MLMI '20) içinde, ss. 1-7, Ara. 2020. DOI: 10.1145/3426826.3426832.

[4] A. Rasheed ve diğerleri, "Fabric Defect Detection Using Computer Vision Techniques: A Comprehensive Review," Mathematical Problems in Engineering, cilt 2020, makale no. 8189403, Kas. 2020. DOI: 10.1155/2020/8189403.

Bizi dinlediğiniz için

TEŞEKKÜR EDERİZ